

# Лекции по Численным методам

Лектор: Тараканов Александр

Весна 2024

## Содержание

<b>1</b>	<b>Прямые методы решения систем линейных уравнений</b>	<b>2</b>
1.1	Нижние и верхние треугольные матрицы	2
1.2	Решение системы уравнений с помощью LU разложения	3
1.3	Решение системы уравнений с помощью разложения Холецкого	5
1.4	Решение систем уравнений с помощью алгоритма Гаусса	6
<b>2</b>	<b>Норма и анализ сходимости</b>	<b>7</b>
2.1	Векторные $l_p$ нормы	7
2.2	Сходимость по норме	9
2.3	Норма линейного оператора	9
2.4	Число обусловленности	11
2.5	Число обусловленности и устойчивость решения системы уравнений	11
<b>3</b>	<b>Итерационные методы</b>	<b>12</b>
3.1	Метод Якоби	12
3.2	Общий вид итерационного алгоритма	13
3.3	Спектральный радиус и сходимость	13
3.4	Метод Гаусса-Зейделя	15
3.5	Метод Релаксации. SOR	16
<b>4</b>	<b>Методы наискорейшего спуска и сопряженных градиентов</b>	<b>17</b>
4.1	Метод наискорейшего спуска	17
4.2	Метод сопряженных градиентов	19
<b>5</b>	<b>Метод бисопряженных градиентов</b>	<b>22</b>
5.1	Алгоритм	23
5.2	Доказательство алгоритма	23
5.3	Проблемы алгоритма	23
<b>6</b>	<b>Предобуславливание</b>	<b>24</b>
<b>7</b>	<b>Собственные векторы и собственные значения</b>	<b>25</b>
7.1	Степенной метод	25
7.2	QR-разложение	26

# 1 Прямые методы решения систем линейных уравнений

## Постановка задачи

Рассмотрим систему уравнений:

$$\begin{cases} A_{11}x_1 + \dots + A_{1n}x_n = y_1 \\ \dots \\ A_{n1}x_1 + \dots + A_{nn}x_n = y_n \end{cases} \quad (1)$$

Система уравнений (1) называется линейной системой уравнений (СЛУ).  $A_{ij}$  — матрица коэффициентов,  $y_i$  — правая часть и  $x_i$  — неизвестные

Про СЛУ естественно говорить на языке линейных пространств и операторов: пусть задан линейный оператор  $A : X \rightarrow Y$ , вектор  $y \in Y$  и требуется найти его прообраз  $x \in X : Ax = y$

## Предположения

В общем случае при решении СЛУ возможны несколько случаев:

- Решение существует и единственно  $\ker A = 0$  и  $y \in \operatorname{Im} A$
- Решение существует, но не единственно  $\ker A \neq 0$  и  $y \in \operatorname{Im} A$
- Решения не существует  $y \notin \operatorname{Im} A$

В данном курсе мы будем рассматривать только частный случай:  $\ker A = 0$  и  $\operatorname{Im} A = Y$  или  $\operatorname{coker} A = 0$

Иными словами: будем считать, что  $X$  и  $Y$  — линейные пространства одинаковой размерности  $n$ , матрица СЛУ  $A$  является несингулярной (квадратной и невырожденной)

В такой постановке задача  $Ax = y$  определена корректно и решение существует и единственно для любой правой части

Далее в курсе будут разбираться различные алгоритмы поиска решения в зависимости от свойств матрицы  $A$

### 1.1 Нижние и верхние треугольные матрицы

**Определение 1.** Матрица  $L$  называется *нижней треугольной* матрицей, если  $L_{ij} = 0$ , если  $j > i$

**Определение 2.** Матрица  $U$  называется *верхней треугольной* матрицей, если  $U_{ij} = 0$ , если  $j < i$

Нижние и верхние треугольные матрицы обладают следующим важным свойством

**Утверждение 3.** Пусть  $A$  и  $B$  нижние (верхние) треугольные матрицы, то и матрица  $C = AB$  является нижней (верхней) треугольной матрицей

*Доказательство.* Для доказательства вычислим значение матричного элемента  $C_{ij}$  при  $j > i$  для нижних треугольных матриц:

$$C_{ij} = \sum_{k=1}^n A_{ik} \cdot B_{kj} = \sum_{k=1}^i A_{ik} \cdot B_{kj} + \sum_{k=i+1}^n A_{ik} \cdot B_{kj} = \sum_{k=1}^i A_{ik} \cdot 0 + \sum_{k=i+1}^n 0 \cdot B_{kj} = 0$$

□

### Решение системы с нижней треугольной матрицей

Рассмотрим СЛУ с нижней треугольной матрицей  $L$ :

$$\begin{cases} L_{11}x_1 & = y_1 \\ L_{21}x_1 + L_{22}x_2 & = y_2 \\ \dots & \\ L_{n1}x_1 + \dots + L_{nn}x_n & = y_n \end{cases}$$

Тогда решение можно найти, исключая неизвестные:

$$\begin{aligned} x_1 &= y_1/L_{11} \\ x_2 &= (y_2 - L_{21}x_1)/L_{22} \\ &\dots \\ x_i &= \left( y_i - \sum_{j=1}^{i-1} L_{ij}x_j \right) / L_{ii} \\ &\dots \end{aligned}$$

### Решение системы с верхней треугольной матрицей

Рассмотрим СЛУ с верхней треугольной матрицей  $U$ :

$$\begin{cases} U_{11}x_1 + \dots + U_{1n}x_n &= y_1 \\ \dots & \\ U_{(n-1)(n-1)}x_{n-1} + \dots + U_{(n-1)n}x_n &= y_{n-1} \\ U_{nn}x_n &= y_n \end{cases}$$

Тогда решение можно найти, исключая неизвестные:

$$\begin{aligned} x_n &= y_n/U_{nn} \\ x_{n-1} &= (y_{n-1} - U_{(n-1)n}x_n)/U_{(n-1)(n-1)} \\ &\dots \\ x_i &= \left( y_i - \sum_{j=i+1}^n U_{ij}x_j \right) / U_{ii} \\ &\dots \end{aligned}$$

## 1.2 Решение системы уравнений с помощью LU разложения

Пусть есть СЛУ  $Ax = y$

Идея алгоритма состоит в следующем:

- Представить матрицу  $A$  в виде произведения:  $A = LU$ , где  $L$  — нижняя треугольная матрица,  $U$  — верхняя треугольная
- Решить систему  $Lz = y$
- Решить систему  $Ux = z$

*Доказательство.* Пусть  $x$  — решение исходной системы. Тогда

$$Ax = LUx = L(Ux) = Lz = y$$

□

### Замечание

- В общем случае LU разложение не определено однозначно: если  $D$  — невырожденная диагональная матрица, то можно построить другое LU разложение по уже имеющемуся:

$$A = LU = LDD^{-1}U = (LD)(D^{-1}U) = L'U'$$

Данную неопределенность можно решить, зафиксировав, что  $L_{ii} = 1$  или  $U_{ii} = 1$

## Алгоритм построения LU разложения

Рассмотрим случай, когда диагональ верхней треугольной матрицы  $U_{ii} = 1$ . Будем вычислять элементы матриц  $L$  и  $U$  построчно:

- Первая строка:  $L_{11}U_{11} = A_{11}$  и  $U_{11} = 1$ , поэтому  $L_{11} = A_{11}/U_{11}$  (перемножили 1-ую строку и 1-ый столбец). Далее вычислим  $U_{1i}$ : (перемножаем 1-ую строку и  $i$ -ый столбец)

$$L_{11}U_{1i} = A_{1i} \iff U_{1i} = A_{1i}/L_{11}$$

- Вторая строка:  $L_{21}U_{11} = A_{21}$  и  $U_{11} = 1$ , поэтому  $L_{21} = A_{21}/U_{11}$  (перемножили 1-ую строку и 2-ый столбец). Далее вычислим  $L_{22}$ : (перемножим 2-ую строку и 2-ый столбец)

$$L_{21}U_{12} + L_{22}U_{22} = A_{22} \iff L_{22} = (A_{22} - L_{21}U_{12})/U_{22}$$

Теперь вычислим  $U_{2i}$ : (перемножим 2-ую строку и  $i$ -ый столбец)

$$L_{21}U_{12} + L_{22}U_{2i} = A_{2i} \iff U_{2i} = (A_{2i} - L_{21}U_{12})/L_{22}$$

И так далее

- В итоге получаем, что вычислить  $i$ -ую строку матрицы  $L$ , можно следующим образом: ( $j \leq i$ )

$$L_{ij} = \left( A_{ij} - \sum_{k=1}^{j-1} L_{ik}U_{kj} \right) / U_{jj}$$

А  $i$ -ая строка матрицы  $U$  вычисляется так: ( $j > i$ )

$$U_{ij} = \left( A_{ij} - \sum_{k=1}^{i-1} L_{ik}U_{kj} \right) / L_{ii}$$

**Замечание** Если мы задаем диагональные элементы нижней треугольной матрицы  $L$ , то задача сводится к уже решенной:

$$A^\top = L'U' \iff A = (U')^\top (L')^\top = LU$$

Данный алгоритм позволяет найти LU разложение для матрицы  $A$  единственным образом, если зафиксировать диагональные элементы матрицы  $U$  или  $L$ . Однако если на  $m$ -ом шаге окажется, что  $L_{mm} = 0$ , то алгоритм позволяет найти только лишь LU разложение главного минора порядка  $m$  матрицы  $A$ :

$$[A]_m = [L]_m[U]_m,$$

где  $[L]_m$  и  $[U]_m$  — нижняя и верхняя треугольные матрицы, вычисленные за  $m$  шагов

В общем случае, данный алгоритм не гарантирует сходимости к LU разложению для матрицы  $A$ , однако существует класс матриц  $A$ , для которых алгоритм корректно находит LU разложение

## Класс матриц

Необходимо проверить, есть ли нули на диагонали матрицы  $L$ , тогда вышеописанный алгоритм будет работать корректно

**Утверждение 4.** Если  $\forall m \in \{1, \dots, n\} : \det[A]_m \neq 0$ , то  $L_{mm} \neq 0$

*Доказательство.* Докажем от противного. Зафиксируем  $m \in \{1, \dots, n\}$  и  $\det[A]_m \neq 0$ . Пусть  $L_{ii} \neq 0$  при  $i < m$  и  $L_{mm} = 0$ . Тогда верно, что

$$[A]_m = [L]_m[U]_m \implies \det[A]_m = \det[L]_m \cdot \det[U]_m = \prod_{i=1}^m L_{ii} \cdot \prod_{i=1}^m U_{ii} = 0$$

Получили противоречие, что определитель главного минора  $[A]_m$  не равен 0

□

В общем случае данное утверждение сложно проверить. Если матрица является симметричной положительно определенной (SPD), то тогда оно выполнено по [критерию Сильвестра](#)

Помимо SPD матриц, часто встречаются матрицы со следующим особым свойством

**Определение 5.** Матрица  $A$  называется *матрицей с диагональным преобладанием*, если  $\forall i \in \{1, \dots, n\}$

$$|A_{ii}| - \sum_{j \neq i} |A_{ij}| > 0$$

Видно, что главный минор такой матрицы также является матрицей с диагональным преобладанием. Докажем следующее утверждение

**Утверждение 6.** Матрица с диагональным преобладанием является несингулярной

*Доказательство.* Докажем от противного. Пусть матрица вырожденная. Тогда  $\exists x \in \mathbb{R}^n : Ax = 0$ . Найдем максимальный по модулю элемент в векторе  $x : |x_i| = \max_j |x_j|$  и рассмотрим  $i$ -ую строку  $Ax$ :

$$0 = \left| \sum_j A_{ij} x_j \right| = |x_i| \cdot \left| \sum_j A_{ij} \frac{x_j}{|x_i|} \right| = |x_i| \cdot \left| A_{ii} + \sum_{j \neq i} A_{ij} \cdot \frac{x_j}{|x_i|} \right| \geq |x_i| \cdot \left| A_{ii} - \sum_{j \neq i} |A_{ij}| \cdot \frac{|x_j|}{|x_i|} \right| > 0$$

Предпоследнее неравенство верно по обратному неравенству треугольника. Последнее неравенство верно, так как матрица  $A$  является матрицей с диагональным преобладанием, а отношение  $|x_j|/|x_i| < 1$  при  $j \neq i$ .

Получили противоречие  $\square$

### 1.3 Решение системы уравнений с помощью разложения Холецкого

Пусть есть СЛУ  $Ax = y$  и матрица  $A$  является SPD матрицей. Тогда существует специальный вид (причем единственный) LU разложения — разложение Холецкого:

$$A = LL^\top,$$

где  $L$  — нижняя треугольная матрица с положительными элементами на диагонали

**Утверждение 7.** *Существование разложения Холецкого*

*Доказательство.* Пусть задано какое-то LU разложение:  $A = LU$  (существование его доказывалось ранее). Тогда верно следующее:

$$LU = A = A^\top = U^\top L^\top$$

Домножим слева равенство на  $L^{-1}$ :

$$U = L^{-1}U^\top L^\top$$

Теперь домножим справа равенство на  $(L^\top)^{-1}$ :

$$U(L^\top)^{-1} = L^{-1}U^\top = D$$

Получим, что слева у нас верхняя треугольная матрица, а справа нижняя треугольная матрица, поэтому и справа, и слева диагональная матрица  $D$

Рассмотрим исходное LU разложение:

$$A = LU = L \cdot (DL^\top) = LD^{1/2}D^{1/2}L^\top = (LD^{1/2})(LD^{1/2})^\top = L'L'^\top$$

Причем диагональные элементы  $D$  могут быть только положительными, так как  $A$  является SPD матрицей и  $L$  — матрица перехода от одного базиса к другому  $\square$

**Утверждение 8.** *Единственность разложения Холецкого*

*Доказательство.* Единственность доказывается вместе с построением алгоритма вычисления, аналогичному для LU разложения

- $L_{11}L_{11} = A_{11} \iff L_{11} = \sqrt{A_{11}}$
- $i$ -ая строка при  $j < i$ :

$$\sum_{k=1}^{j-1} L_{ik}L_{kj} + L_{ij}L_{jj} = A_{ij} \iff L_{ij} = \left( A_{ij} - \sum_{k=1}^{j-1} L_{ik}L_{kj} \right) / L_{jj}$$

- Диагональные элементы  $L_{ii}$ :

$$L_{ii} = \sqrt{A_{ii} - \sum_{k=1}^{j-1} L_{ik}L_{kj}}$$

□

## 1.4 Решение систем уравнений с помощью алгоритма Гаусса

Пусть есть СЛУ  $Ax = y$

Будем решать ее алгоритмом Гаусса: сначала применять прямой алгоритм Гаусса, потом обратный. Данный алгоритм является одним из способов построения LU разложения

Во время прямого алгоритма Гаусса мы будем приводить матрицу  $A$  к ступенчатому виду, выполняя операции над строками:

- 1 тип:  $i \mapsto i \cdot \lambda, \lambda \neq 0$
- 2 тип:  $i \leftrightarrow j$
- 3 тип:  $i \mapsto i + j \cdot \lambda$

Во время обратного хода мы теми же действиями будем приводить матрицу  $A$  к улучшенному ступенчатому виду, чтобы главные коэффициенты были равны 1

Каждой операции над строками однозначно сопоставляется умножение слева на матрицу

Сложность алгоритма Гаусса составляет  $O(n^3)$ , где  $n$  — размерность матрицы  $A$ . Поэтому данные алгоритмы не используются для решения СЛУ больших размерностей

## 2 Норма и анализ сходимости

**Определение 9.** Пусть задано линейное векторное пространство  $V$  над полем  $\mathbb{R}$ . Функцию  $\|\cdot\| : V \rightarrow \mathbb{R}$  будем называть *нормой*, если выполнены следующие свойства:

- $\forall x \in V : \|x\| \geq 0$
- $\|x\| = 0 \iff x = 0$
- $\|\alpha x\| = |\alpha| \cdot \|x\|$
- $\forall x, y \in V : \|x + y\| \leq \|x\| + \|y\|$  — неравенство треугольника

Пространство  $V$  с нормой  $\|\cdot\|$  называется *нормированным пространством*

### 2.1 Векторные $l_p$ нормы

Важным примером норм является  $l_p$  норма. Пусть  $V = \mathbb{R}^n$ . Тогда для  $x \in V$ , который будем записывать в виде вектор-столбца  $x = [x_1, \dots, x_n]^T$ , определим  $l_p$  норму:

$$\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}$$

Существуют особые виды  $l_p$  нормы:

- $p = 1 : \|x\|_1 = |x_1| + \dots + |x_n|$
- $p = 2 : \|x\|_2 = \sqrt{|x_1|^2 + \dots + |x_n|^2}$
- $p = \infty : \|x\|_\infty = \max_i |x_i|$

**Утверждение 10.** Докажем, что приведенные функции являются нормами

*Доказательство.* Разберем каждый случай по отдельности:

#### 1. Случай $p = 1$

- $\|x\|_1 \geq 0$  очевидно. Пусть  $\|x\| = 0$ . Тогда  $|x_1| + \dots + |x_n| = 0 \iff x_1 = \dots = x_n = 0 \iff x = 0$ . В обратную сторону очевидно
- $\|\alpha x\|_1 = |\alpha x_1| + \dots + |\alpha x_n| = |\alpha| \cdot (|x_1| + \dots + |x_n|) = |\alpha| \cdot \|x\|_1$
- Зафиксируем  $x, y \in V$ . Тогда

$$\|x + y\|_1 = \sum_{i=1}^n |x_i + y_i| \leq \sum_{i=1}^n |x_i| + \sum_{i=1}^n |y_i| = \|x\|_1 + \|y\|_1$$

#### 2. Случай $p = 2$

- Первые три свойства проверяются аналогично. Докажем только неравенство треугольника. Зафиксируем  $x, y \in V$  и воспользуемся [неравенством Коши-Буняковского](#):

$$\|x + y\|_2^2 = \sum_{i=1}^n |x_i + y_i|^2 = \sum_{i=1}^n |x_i|^2 + \sum_{i=1}^n |y_i|^2 + 2 \sum_{i=1}^n |x_i| \cdot |y_i| \leq \|x\|_2^2 + \|y\|_2^2 + 2\|x\|_2 \cdot \|y\|_2 = (\|x\|_2 + \|y\|_2)^2$$

#### 3. Случай $p \in \mathbb{R} : p > 1$

- Первые три свойства проверяются аналогично. Докажем неравенство треугольника

- Предположим, что  $x, y \in V : x \neq 0, y \neq 0$  и  $\forall i \in \{1, \dots, n\} : x_i \geq 0$  без ограничения общности рассуждений.

Зафиксируем  $x$  и будем искать максимум  $f(y) = \|x + y\|_p$  по  $y$  при условии, что  $\|y\|_p = C = \text{const}$ . Из курса математического анализа известно, что непрерывная функция на компакте достигает своего максимума. Пусть  $f(y)$  достигает максимума в точке  $y^*$ .

Тогда запишем уравнение касательной плоскости к поверхности  $\|y\|_p = C$ :  
 $(dy = [dy_1, \dots, dy_n]^\top$  — вектор приращений)

$$\sum_{i=1}^n \frac{\partial}{\partial y_i} \|y\|_p^p dy_i = \sum_{i=1}^n p|y_i|^{p-1} dy_i = 0 = \langle \nabla \|y\|_p^p, dy \rangle \quad (2)$$

- Так как  $y^*$  — точка экстремума функции, то найдем производную  $f(y)^p$ :

$$\frac{d}{dy} f(y^*)^p = \sum_{i=1}^n p|x_i + y_i^*|^{p-1} dy_i = 0 = \langle \nabla f(y^*)^p, dy \rangle \quad (3)$$

- Из (2) в точке  $y^*$  и (3) следует, что векторы

$$\nabla \|y^*\|_p^p = [y_1^{*p-1}, \dots, y_n^{*p-1}]^\top$$

и

$$\nabla f(y^*)^p = [x_1 + y_1^*|^{p-1}, \dots, x_n + y_n^*|^{p-1}]^\top$$

перпендикулярны вектору приращений  $dy$ , а значит коллинеарны:

$$|x_i + y_i^*| = \lambda |y_i^*|$$

- Так как  $y^*$  — точка максимума, то в знаки  $x_i$  и  $y_i^*$  должны совпадать. То есть  $y_i = kx_i$  для некоторого  $k > 0$ , которое можно найти следующим образом:

$$k = \frac{\|y\|_p}{\|x\|_p} = \frac{C}{\|x\|_p}$$

$$\|x + y\|_p \leq \|x + y^*\|_p = \|x + kx\|_p = \|x\|_p + \|kx\|_p = \|x\|_p + \|y\|_p$$

#### 4. Случай $p = \infty$

- Рассмотрим следующий предел:

$$\lim_{p \rightarrow \infty} \|x\|_p$$

- Пусть дан вектор  $x \in V : \|x\|_\infty = |x_k|$ . Тогда

$$\|x\|_\infty = |x_k| = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p} \leq \|x\|_p \leq \left( \sum_{i=1}^n |x_k|^p \right)^{1/p} = n^{1/p} \|x\|_\infty = n^{1/p} |x_k|$$

- Отсюда и из  $n^{1/p} \rightarrow 1$  при  $p \rightarrow \infty$  видно, что  $\|x\|_\infty = \lim_{p \rightarrow \infty} \|x\|_p$
- Теперь мы можем доказать, что  $\|x\|_\infty$  является нормой по предельным переходам

□

**Определение 11.** Пусть задано линейное векторное пространство  $V$  над полем  $\mathbb{R}$ .

Функцию  $\rho : V \times V \rightarrow \mathbb{R}$  будем называть *метрикой*, если выполнены следующие свойства:

- $\forall x, y \in V : \rho(x, y) \geq 0$
- $\rho(x, y) = 0 \iff x = y$



- $\forall x, y \in V : \rho(x, y) = \rho(y, x)$
- $\forall x, y, z \in V : \rho(x, z) \leq \rho(x, y) + \rho(y, z)$  — неравенство треугольника

Пространство  $V$  с метрикой  $\rho$  называется *метрическим пространством*

Заметим, что любая норма на линейном пространстве задает метрику:

$$\rho(x, y) = \|x - y\|$$

## 2.2 Сходимость по норме

**Определение 12.** Две нормы  $\|\cdot\|_a$  и  $\|\cdot\|_b$  (необязательно  $l_p$  нормы) на нормированном пространстве  $V$  называются эквивалентными, если  $\exists C_1, C_2 > 0 : \forall x \in V$

$$C_1 \cdot \|x\|_a \leq \|x\|_b \leq C_2 \cdot \|x\|_a$$

Известно, что на конечномерных пространствах все нормы являются эквивалентными. Будем говорить, что последовательность векторов  $\{x_k\}$  сходится к  $x$  по норме, если  $\|x_k - x\| \rightarrow 0$  при  $k \rightarrow \infty$ . Так как все нормы являются эквивалентными, то для исследования сходимости можно использовать любую норму. Также для конечномерных пространств верно, что из покоординатной сходимости следует сходимость по норме и наоборот

## 2.3 Норма линейного оператора

**Определение 13.** Пусть задано нормированное пространство  $V$  с нормой  $\|x\|$ . Пусть задан линейный оператор  $A : V \rightarrow V$ . Определим норму линейного оператора следующим образом:

$$\|A\| = \sup_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|}$$

**Утверждение 14.** Докажем, что это действительно норма, и перечислим свойства

- Первые три свойства нормы выполняются
- Проверим неравенство треугольника:

$$\|A + B\| = \sup_{\|x\| \neq 0} \frac{\|Ax + Bx\|}{\|x\|} \leq \sup_{\|x\| \neq 0} \left( \frac{\|Ax\|}{\|x\|} + \frac{\|Bx\|}{\|x\|} \right) \leq \sup_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|} + \sup_{\|x\| \neq 0} \frac{\|Bx\|}{\|x\|} = \|A\| + \|B\|$$

- Видно из определения нормы, что

$$\|Ax\| \leq \|A\| \cdot \|x\|$$

- Оценим сверху норму композиции операторов  $BA$ :

$$\|BAx\| = \|B(Ax)\| \leq \|B\| \cdot \|Ax\| \leq \|B\| \cdot \|A\| \cdot \|x\|$$

Поэтому  $\|BA\| \leq \|B\| \cdot \|A\|$

- Из линейности оператора следует, что

$$\sup_{\|x\| \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{\|x\| \neq 0} \left\| A \cdot \left( \frac{x}{\|x\|} \right) \right\| = \sup_{\|x\|=1} \|Ax\|$$

По этой причине норма любого линейного оператора на конечномерном линейном пространстве с  $l_p$  нормой существует и конечна

## Примеры

- Норма диагонального оператора  $D_{n \times n} = D$  с помощью  $l_p$  нормы:

$$\sup_{\|x\|=1} \|Dx\|_p = \left( \sum_{i=1}^n |D_{ii}|^p \cdot |x_i|^p \right)^{1/p}$$

Пусть  $D_{kk} = \max_i |D_{ii}|$ . Тогда

$$\left( \sum_{i=1}^n |D_{ii}|^p \cdot |x_i|^p \right)^{1/p} \leq \left( \sum_{i=1}^n |D_{kk}|^p \cdot |x_i|^p \right)^{1/p} = |D_{kk}| \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}$$

Получается, что

$$\sup_{\|x\|=1} \|Dx\|_p \leq \max_i |D_{ii}|$$

Пример, на котором достигается максимум легко построить: возьмем  $x = [0, \dots, 1, \dots, 0]^\top$  — ненулевая координата только на  $k$ -ой позиции

- Рассмотрим  $l_2$  норму на конечномерном линейном пространстве  $V$ . Пусть есть некоторый оператор  $A$ . Известно, что любой оператор можно разложить в виде композиции поворотов, отражений и растяжений вдоль осей с положительными коэффициентами — [SVD](#):

$$A = U_1 D U_2,$$

где  $U_1, U_2$  — ортогональные матрицы, которые сохраняют расстояние  $\|U_1 x\| = \|U_2 x\| = \|x\|$

$$\|A\| = \sup_{\|x\|=1} \|Ax\| = \sup_{\|x\|=1} \|U_1 D U_2 x\| = \sup_{\|x\|=1} \|D U_2 x\| = \sup_{\|x\|=1} \|Dx\| = \max_i D_{ii}$$

- Рассмотрим  $l_2$  норму на конечномерном линейном пространстве  $V$ . Пусть есть некоторый самосопряженный оператор  $A$  (заданный SPD матрицей). Тогда представим его в следующем виде:

$$A = U D U^\top,$$

где  $U$  — ортогональная матрица,  $D$  — диагональная матрица из собственных значений  $\lambda_i$ . Аналогично предыдущему пункту:

$$\|A\| = \max_i \lambda_i$$

- Рассмотрим  $l_\infty$  норму на конечномерном линейном пространстве  $V$  и произвольный оператор  $A$

$$\|A\| = \sup_{\|x\|=1} \|Ax\|_\infty = \max_i \left| \sum_j A_{ij} x_j \right| = \left| \sum_j A_{kj} x_j \right|$$

Заметим, что  $A_{kj}$  и  $x_j$  должны быть одного знака, иначе можно поменять знак координаты  $j$  вектора  $x$  на противоположный и значение увеличится, что противоречит максимальности выражения. Так как  $\|x\|_\infty = 1$ , тогда есть координата  $|x_m| = 1$ . Тогда заменим все  $x_j$  на 1, от этого норма не изменится. В итоге получили, что

$$\|A\| = \max_i \left| \sum_j A_{ij} \right|$$

## 2.4 Число обусловленности

**Определение 15.** Пусть на нормированном конечномерном пространстве  $V$  задан невырожденный линейный оператор  $A : V \rightarrow V$ . Числом обусловленности линейного оператора будем называть следующее выражение:

$$\kappa(A) = \|A\| \cdot \|A^{-1}\|$$

Видно, что  $\kappa(A) = \kappa(A^{-1})$

**Утверждение 16.** Число обусловленности  $\kappa(A) \geq 1$

*Доказательство.*

$$\|x\| = \|A^{-1}Ax\| \leq \|A^{-1}\| \cdot \|Ax\| \leq \|A^{-1}\| \cdot \|A\| \cdot \|x\| = \kappa(A) \cdot \|x\|$$

□

**Утверждение 17.** Пусть  $A$  — самосопряженный линейный оператор и задана  $l_2$  норма. Тогда число обусловленности равно

$$\kappa(A) = \frac{\max_i \lambda_i}{\min_i \lambda_i},$$

где  $\lambda_i$  — собственное значение матрицы  $A$

*Доказательство.* Докажем, что

$$\kappa(A) = \frac{\sup_{\|x\|=1} \|Ax\|}{\inf_{\|x\|=1} \|Ax\|}$$

- Так как  $A$  — самосопряженный оператор, то  $A = U^\top D U$  и  $A^{-1} = U^\top D^{-1} U$
- Найдем  $\|A^{-1}\|$

$$\|A^{-1}\| = \sup_{\|x\| \neq 0} \frac{\|A^{-1}x\|}{\|x\|} = \sup_{\|y\| \neq 0} \frac{\|A^{-1}Ay\|}{\|Ay\|} = \sup_{\|y\| \neq 0} \frac{\|y\|}{\|Ay\|} = \frac{1}{\inf_{\|x\|=1} \|Ax\|}$$

- Отсюда и так как задана  $l_2$  норма получаем нужное равенство через собственные значения

□

В общем случае, число обусловленности показывает, насколько матрица близка к сингулярной: чем больше число обусловленности, тем ближе к сингулярности

## 2.5 Число обусловленности и устойчивость решения системы уравнений

Рассмотрим СЛУ  $Ax = b$ . Допустим, что правая часть  $b$  известна с точностью до ошибок  $\Delta b$ . Тогда мы решаем систему  $Ax^* = b + \Delta b$

Пусть погрешность тогда равна  $\Delta x = x^* - x$ . Оценим относительную ошибку:

$$\frac{\|\Delta x\|}{\|x\|} = \frac{\|A^{-1}\Delta b\|}{\|x\|} \leq \|A^{-1}\| \cdot \frac{\|\Delta b\|}{\|b\|} \cdot \frac{\|b\|}{\|x\|} = \|A^{-1}\| \cdot \frac{\|\Delta b\|}{\|b\|} \cdot \frac{\|Ax\|}{\|x\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\Delta b\|}{\|b\|} = \kappa(A) \cdot \frac{\|\Delta b\|}{\|b\|}$$

Рассмотрев  $A^{-1}b = x$  аналогично можно получить следующую оценку:

$$\frac{1}{\kappa(A)} \cdot \frac{\|\Delta b\|}{\|b\|} \leq \frac{\|\Delta x\|}{\|x\|} \leq \kappa(A) \cdot \frac{\|\Delta b\|}{\|b\|}$$

СЛУ, где матрица  $A$  имеет большое число обусловленности, могут иметь неустойчивые решения, которые могут сильно отличаться от аналитического решения

### 3 Итерационные методы

#### Постановка задачи

Рассмотрим СЛУ  $Ax = y$ . Предположим, что матрица  $A$  является матрицей с диагональным преобладанием

#### 3.1 Метод Якоби

##### Описание алгоритма

Рассмотрим  $i$ -ую строку:

$$\sum_{k=1}^n A_{ik}x_k = b_i \iff x_i = \left( b_i - \sum_{k \neq i} A_{ik}x_k \right) / A_{ii}$$

Будем теперь находить решение СЛУ итерационно, сперва проинициализировав  $x_i^{(1)}$ : ( $t$  — номер итерации)

$$x_i^{(t+1)} = \left( b_i - \sum_{k \neq i} A_{ik}x_k^{(t)} \right) / A_{ii}$$

Пусть  $D$  — матрица диагональных элементов матрицы  $A$ . Тогда итерационный процесс можно записать в матричной форме:

$$x^{(t+1)} = (I - D^{-1}A)x^{(t)} + D^{-1}b$$

##### Сходимость метода Якоби

**Утверждение 18.** *Метод Якоби сходится для любой стартовой точки*

*Доказательство.* Докажем, что  $x^{(t)}$  сходится по [критерию Коши](#)

- Рассмотрим  $\Delta_t = x^{(t+1)} - x^{(t)}$ .

$$\Delta_t = (I - D^{-1}A)x^{(t)} + D^{-1}b - (I - D^{-1}A)x^{(t-1)} - D^{-1}b = (I - D^{-1}A)(x^{(t)} - x^{(t-1)}) = (I - D^{-1}A)\Delta_{t-1}$$

Пусть  $G = (I - D^{-1}A)$  — будем называть *итерационным оператором*. Покажем, что  $\|G\| < 1$  при  $l_p$  норме, где  $p = \infty$

$$\|G\|_\infty = \max_i \sum_j |G_{ij}| = \max_i \left( \sum_j \frac{|A_{ij}|}{|A_{ii}|} - 1 \right) = \max_i \sum_{j \neq i} \frac{|A_{ij}|}{|A_{ii}|} < 1,$$

так как  $A$  матрица с диагональным преобладанием

- Теперь оценим  $\|\Delta_t\|_\infty$ :

$$\|\Delta_t\|_\infty = \|G\Delta_{t-1}\|_\infty \leq \|G\|_\infty \|\Delta_{t-1}\|_\infty \leq \dots \leq \|G\|_\infty^{t-1} \cdot \|\Delta_1\|_\infty$$

- Рассмотрим теперь критерий Коши:

$$\begin{aligned} \|x^{(t+q)} - x^{(t)}\|_\infty &= \left\| x^{(1)} + \sum_{i=1}^{t+q-1} \Delta_i - x^{(1)} - \sum_{i=1}^{t-1} \Delta_i \right\|_\infty = \left\| \sum_{i=t}^{t+q-1} \Delta_i \right\|_\infty \leq \sum_{i=t+1}^{t+q} \|\Delta_i\|_\infty \leq \sum_{i=t+1}^{t+q} \|G\|_\infty^{i-1} \cdot \|\Delta_1\|_\infty = \\ &= \|G\|_\infty^t \cdot \frac{1 - \|G\|_\infty^{t+q}}{1 - \|G\|_\infty} \cdot \|\Delta_1\|_\infty \end{aligned}$$

Так как  $\|G\|_\infty < 1$ , то при  $t \rightarrow \infty$

$$\|x^{(t+q)} - x^{(t)}\|_\infty \leq \|G\|_\infty^t \cdot \frac{1}{1 - \|G\|_\infty} \cdot \|\Delta_1\|_\infty \rightarrow 0$$

- Так как последовательность  $x^{(t)}$  фундаментальная, то она сходится к некоторому  $x^*$ , что и будет решением СЛУ. Переходя к пределу в равенстве для  $x^{(t+1)}$ , получаем, что

$$x^* = (I - D^{-1}A)x^* + D^{-1}b \iff Ax^* = b$$

□

### 3.2 Общий вид итерационного алгоритма

Рассмотрим СЛУ  $Ax = y$ . Пусть  $Q$  — обратимая матрица (матрица расщепления или splitting matrix). Тогда можем преобразовать СЛУ следующим образом:

$$Qx = (Q - A)x + y$$

Тогда легко видеть, что решение  $x$  вычисляется следующим образом:

$$x = (I - Q^{-1}A)x + Q^{-1}y$$

Тогда построим итерационную последовательность  $x^{(t)}$ :

$$x^{(t+1)} = (I - Q^{-1}A)x^{(t)} + Q^{-1}y$$

В общем виде последовательность имеет вид:

$$x^{(t+1)} = Gx^{(t)} + c$$

### 3.3 Спектральный радиус и сходимость

**Определение 19.** Спектральным радиусом линейного оператора  $A$  называется следующая величина:

$$\rho(A) = \sup\{|\lambda| : \lambda \in \text{spec}(A)\},$$

где  $\text{spec}(A)$  — множество собственных значений (спектр) оператора  $A$

Сходимость нашей итерационной последовательности определяется спектральным радиусом матрицы  $G$

**Утверждение 20.** Процесс сходится из любой стартовой точки, если  $\rho(A) < 1$

*Доказательство.* Докажем сначала, что при  $\rho(A) \geq 1$  итерационный процесс расходится, а потом докажем сходимость в обратном случае

- Пусть  $v$  — собственный вектор с собственным значением  $|\lambda| \geq 1$ . Тогда запустим два итерационных процесса из разных точек:  $x^{(1)}$  и  $\xi^{(1)} = x^{(1)} + v$ . Рассмотрим их разность на  $t$ -ой итерации:

$$\|x^{(t)} - \xi^{(t)}\|_\infty = \|G^t(x^{(1)} - \xi^{(1)})\|_\infty = \|G^t v\|_\infty = |\lambda|^t \cdot \|v\|_\infty$$

Видно, что при  $|\lambda| \geq 1$  не могут одновременно сходиться

- Основная идея: если  $\rho(G) < 1$ , то можно построить такую норму  $\|\cdot\|$ , что  $\|G\| < 1$ . Тогда доказать утверждение можно аналогично методу Якоби

Вспомним, что матрица  $G$  разбивается на блоки — [жорданова нормальная форма](#)

$$\begin{pmatrix} \lambda & 1 & 0 & \cdots & 0 \\ 0 & \lambda & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \lambda & 1 \\ 0 & 0 & 0 & 0 & \lambda \end{pmatrix}$$

Видно, что ограничение матрицы (оператора)  $G$  на некоторую жорданову клетку имеет вид линейной комбинации тождественного и нильпотентного оператора:

$$G|_{\text{cell}} = \lambda I + N$$

Тогда и сама матрица  $G$  в жордановом базисе имеет вид:

$$G = \begin{pmatrix} \lambda_1 I_1 + N_1 & & & & \\ & \lambda_2 I_1 + N_2 & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & \lambda_n I_n + N_n \end{pmatrix}$$

Рассмотрим одну жорданову клетку. Для нее существует такой вектор  $v$ , что набор векторов  $v, Nv, N^2v, \dots, N^{k-1}v$  — образуют базис для некоторого подпространства. Более того  $N^k v = 0$ , так как  $N$  — нильпотентный оператор (матрица сдвига). Если жорданова клетка имеет стандартный вид, то тогда  $v = [0, \dots, 0, 1, 0, \dots, 0]^\top$  (1 стоит на  $k$ -ом месте)

Тогда возьмем следующий базис  $w_i = \varepsilon^{-i} N^i v$  для некоторого  $\varepsilon > 0$  и  $i \in \{0, \dots, k-1\}$ . Рассмотрим жорданову клетку в этом базисе:

$$(\lambda I + N)w_i = \lambda w_i + Nw_i = \lambda w_i + N\varepsilon^{-i} N^i v = \lambda w_i + \varepsilon \cdot \varepsilon^{-(i+1)} N^{i+1} v = \lambda w_i + \varepsilon w_{i+1}$$

Получается, что жорданова клетка в этом базисе имеет вид:

$$\begin{pmatrix} \lambda & \varepsilon & 0 & \cdots & 0 \\ 0 & \lambda & \varepsilon & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \lambda & \varepsilon \\ 0 & 0 & 0 & 0 & \lambda \end{pmatrix}$$

Прделаем так с каждой жордановой клеткой матрицы  $G$ . Получаем матрицу  $S$  перехода из одного базиса в другой и матрицу  $G$  в виде:

$$S^{-1}GS = \begin{pmatrix} \lambda_1 I_1 + \varepsilon N_1 & & & & \\ & \lambda_2 I_1 + \varepsilon N_2 & & & \\ & & \ddots & & \\ & & & \ddots & \\ & & & & \lambda_n I_n + \varepsilon N_n \end{pmatrix}$$

Рассмотрим  $l_\infty$  норму в построенном новом базисе и получим, что

$$\|G\|_\infty = \max_i \sum_j |G_{ij}| = \max_i (\lambda_j + \varepsilon) = \rho(G) + \varepsilon$$

Так как  $\rho(G) < 1$ , то можно подобрать такое  $\varepsilon > 0$ , что  $\|G\|_\infty < 1$ . Далее доказываем аналогично методу Якоби

□

### 3.4 Метод Гаусса-Зейделя

В отличие от прошлого метода, в методе Гаусса-Зейделя чтобы посчитать все координаты вектора  $x^{(t+1)}$ , можно использовать не только  $x^{(t)}$ , но и уже посчитанные координаты этого вектора на этой же итерации

#### Описание алгоритма

Пусть  $x^{(t)}$  — решение на  $t$  шаге. Тогда на следующем шаге решение вычисляется следующим образом:

$$x_i^{(t+1)} = \left( b_i - \sum_{j<i} A_{ij}x_j^{(t+1)} - \sum_{j>i} A_{ij}x_j^{(t)} \right) / A_{ii}$$

Пусть матрица  $A = L + U^*$ , где  $L$  — нижняя треугольная матрица,  $U^*$  — строго верхняя треугольная матрица (нулевая диагональ). Тогда уравнение можно переписать в виде:

$$Ax = y \iff Lx = b - U^*x \implies x^{(t+1)} = L^{-1}(b - U^*x^{(t)})$$

Или в ином виде:

$$x^{(t+1)} = (I - L^{-1}A)x^{(t)} + L^{-1}y$$

**Замечание** Метод Гаусса-Зейделя дает небольшой выигрыш по памяти, так как можем перезаписывать значения вектора  $x^{(t)}$ , и имеет может иметь чуть лучшую сходимость и точность, так как мы переиспользуем уже вычисленные значения

#### Сходимость метода Гаусса-Зейделя

**Утверждение 21.** Метод Гаусса-Зейделя сходится для любой стартовой точки.

*Доказательство.* Согласно 20 достаточно доказать, что  $G = I - L^{-1}A$  такая, что  $\rho(G) < 1$

Пусть  $x$  — собственный вектор с собственным значением  $\lambda$  матрицы  $G$ . Тогда

$$Gx = (I - L^{-1}A)x = \lambda x$$

Домножим это равенство справа на матрицу  $L$ :

$$L \cdot (I - L^{-1}A)x = (L - A)x = -Ux = \lambda Lx$$

Пусть теперь  $i : |x_i| = \max_j |x_j| > 0$  и перепишем верхнее равенство в координатной форме:

$$\lambda A_{ii}x_i + \lambda \sum_{j<i} A_{ij}x_j = - \sum_{j>i} A_{ij}x_j$$

Оценим собственное значение  $\lambda$  по модулю, воспользовавшись обратным неравенством треугольника и поделим на  $x_i$ :

$$|\lambda| \cdot \left( A_{ii} - \sum_{j<i} |A_{ij}| \right) \leq \sum_{j>i} |A_{ij}|$$

Отсюда и, вспомнив, что  $A$  — матрица с диагональным преобладанием, следует, что

$$|\lambda| \leq \frac{\sum_{j>i} |A_{ij}|}{A_{ii} - \sum_{j<i} |A_{ij}|} < 1$$

□

### 3.5 Метод Релаксации. SOR

Теперь пусть матрица  $A$  — эрмитовый (самосопряженный) оператор, то есть:

$$A = A^*,$$

где  $A^*$  — транспонированная комплексно-сопряженная матрица  $A$

#### Описание алгоритма

Пусть  $\alpha > 1/2$  — некоторый параметр,  $D$  — диагональ матрицы  $A$  и матрица  $C$  такая, что  $C + C^* = D - A$ .

Тогда матрицы расщепления возьмем  $Q = \alpha D - C$  и получаем итерационный процесс:

$$x^{(t+1)} = (I - Q^{-1}A)x^{(t)} + Q^{-1}b,$$

который сходится к решению нашей СЛУ

#### Сходимость метода релаксации

**Утверждение 22.** *Полученный итерационный процесс сходится для любой стартовой точки*

*Доказательство.* Согласно 20 достаточно доказать, что  $G = I - Q^{-1}A$  такая, что  $\rho(G) < 1$ .

Пусть  $x$  — собственный вектор с собственным значением  $\lambda$  матрицы  $G$ . Тогда

$$Gx = (I - Q^{-1}A)x = \lambda x$$

Введем теперь вектор  $y = (I - G)x = x - Gx$

Заметим, что

$$y = (I - G)x = (I - I + Q^{-1}A)x = Q^{-1}Ax \implies (\alpha D - C)y = Ax$$

А также, что

$$(Q - A)y = Ax - Ay = A(x - y) = AGx \iff (\alpha D - D + C^*)y = AGx$$

Домножим первое и второе равенство на скалярно (эрмитово скалярное произведение)  $y$ :

$$\begin{cases} \alpha \langle Dy, y \rangle - \langle Cy, y \rangle = \langle Ax, y \rangle \\ \alpha \langle y, Dy \rangle - \langle y, Dy \rangle + \langle y, C^*y \rangle = \langle y, AGx \rangle \end{cases}$$

Так как  $D$  — тоже эрмитова матрица, то  $\langle Dy, y \rangle = \langle y, Dy \rangle$ . Также верно, что  $\langle Cy, y \rangle = \langle y, C^*y \rangle$ , так как  $C^*$  сопряженный оператор для  $C$ . Сложим два уравнения и получим:

$$(2\alpha - 1)\langle Dy, y \rangle = \langle Ax, y \rangle + \langle y, AGx \rangle = \langle Ax, x - Gx \rangle + \langle x - Gx, AGx \rangle = (1 - |\lambda|^2) \cdot \langle Ax, x \rangle$$

Так как  $\forall x \neq 0 : \langle Ax, x \rangle > 0$ , то случай  $|\lambda| = 1$  невозможен ( $y = 0$ ), поэтому так как слева и справа положительные числа, то  $|\lambda| < 1$ , что означает, что  $\rho(G) < 1$   $\square$

**Замечание** Можно взять в качестве матрицы  $C$  строго нижнюю часть матрицы  $A$ . Тогда  $C^*$  — строго верхняя часть матрицы  $A$



## 4 Методы наискорейшего спуска и сопряженных градиентов

### Постановка задачи

Рассмотрим СЛУ  $Ax = y$ , где  $A$  — SPD матрицей, то есть

$$A^\top = A$$

и

$$\forall x \neq 0 : x^\top Ax > 0$$

**Определение 23.** *Скалярным произведением* называется функция  $\langle \cdot, \cdot \rangle : V \times V \longrightarrow \mathbb{R}$ , где  $V$  — конечномерное векторное пространство, обладающая следующими свойствами:

- $\forall x, y \in V : \langle x, y \rangle = \langle y, x \rangle$
- $\forall \alpha, \beta \in \mathbb{R}, x, y, z \in V : \langle \alpha x + \beta y, z \rangle = \alpha \langle x, z \rangle + \beta \langle y, z \rangle$
- $\forall x \in V : \langle x, x \rangle > 0$

Иначе говоря, это симметричная положительно определенная билинейная форма

### Примеры

- Самый известный пример скалярного произведения:

$$\langle x, y \rangle = x^\top y$$

- В общем случае скалярное произведение задается матрицей Грамма  $G$  — матрица попарных скалярных произведений базисных векторов:

$$\langle x, y \rangle = \left\langle \sum_i x_i e_i, \sum_j y_j e_j \right\rangle = \sum_{i,j} x_i y_j \langle e_i, e_j \rangle = x^\top G y$$

- Любая SPD матрица задает скалярное произведение:

$$x^\top A y = \langle x, A y \rangle = \langle A x, y \rangle = \langle x, y \rangle_A$$

**Определение 24.** Рассмотрим линейное векторное пространство  $V$  и набор векторов  $\{v_i\}_{i=1}^n$ . Тогда *линейной оболочкой* будем называть подпространство  $L$ :

$$L = \{\lambda_1 v_1 + \dots \lambda_n v_n \mid \lambda_i \in \mathbb{R}\} = \text{span}(v_1, \dots, v_n)$$

**Определение 25.** При наличии скалярного произведения можно говорить об ортогональности между вектором  $x \in V$  и подпространством  $L$ : если  $\forall v_i \in L : \langle v_i, x \rangle = 0$ . Множество векторов, которые ортогональны подпространству  $L$ , называется *ортогональным* и обозначается как  $L^\perp$

### 4.1 Метод наискорейшего спуска

Рассмотрим следующую функцию:

$$F(x) = \frac{1}{2} \langle x, x \rangle_A - b^\top x$$

Данная функция — квадратичная функция с положительно определенным [гессианом](#), поэтому эта функция имеет единственную точку минимума. Найдем ее

- Найдём производную  $F'(x)$ :

$$\begin{aligned}
\frac{\partial F}{\partial x_k} &= \frac{1}{2} \frac{\partial}{\partial x_k} \sum_{i=1}^n x_i \cdot (Ax)_i - \frac{\partial}{\partial x_k} \sum_{i=1}^n b_i \cdot x_i = \\
&= \frac{1}{2} \frac{\partial}{\partial x_k} \sum_{i=1}^n x_i \sum_{j=1}^n A_{ij} x_j - b_k = \frac{1}{2} \frac{\partial}{\partial x_k} \sum_{i,j < n} x_i A_{ij} x_j - b_k = \\
&= \frac{1}{2} \sum_{i=1}^n A_{ik} x_i + \frac{1}{2} \sum_{i=1}^n A_{ki} x_i - b_k = \frac{1}{2} \sum_{i=1}^n (A_{ik} + A_{ki}) x_i - b_k
\end{aligned}$$

Получается, что  $F'(x)$ :

$$F'(x) = \frac{1}{2}(A + A^\top)x - b$$

Вспомним, что  $A$  — симметрическая матрица, тогда  $F'(x) = Ax - b$

- Получается, что задача поиска решения  $Ax = b$  сводится к поиску минимума функции  $F(x)$

### Описание алгоритма

- Решение системы будем искать итерационно. Инициализируем стартовую точку (например,  $x_1 = 0$ )
- $k$ -ую итерацию вычислим рекурсивно:

$$x_{k+1} = x_k - \alpha_k r_k,$$

где  $r_k = b - Ax_k$  — вектор невязки (residual)

Коэффициент  $\alpha_k$  находится из минимизации функции  $F(x_k + \alpha r_k)$  по  $\alpha$ :

$$\begin{aligned}
\frac{\partial}{\partial \alpha} F(x_k + \alpha r_k) &= \frac{1}{2} \frac{\partial}{\partial \alpha} \langle x_k + \alpha r_k, x_k + \alpha r_k \rangle_A - \frac{\partial}{\partial \alpha} \langle b, x_k + \alpha r_k \rangle = \\
&= \frac{1}{2} \frac{\partial}{\partial \alpha} (\langle x_k, x_k \rangle_A + \alpha^2 \langle r_k, r_k \rangle_A + 2\alpha \langle x_k, r_k \rangle_A) - \langle b, r_k \rangle = \\
&= \alpha \langle r_k, r_k \rangle_A + \langle Ax, r_k \rangle - \langle n, r_k \rangle = \alpha \langle r_k, r_k \rangle_A - \langle r_k, r_k \rangle = 0
\end{aligned}$$

Получаем, что

$$\alpha = \frac{\langle r_k, r_k \rangle}{\langle r_k, r_k \rangle_A} = \frac{r_k^\top r_k}{r_k^\top A r_k}$$

- В итоге алгоритм имеет следующий вид:

$$\begin{cases} x_{k+1} = x_k + \alpha_k r_k \\ r_{k+1} = r_k - \alpha_k A r_k \\ \alpha_k = \frac{\langle r_k, r_k \rangle}{\langle r_k, r_k \rangle_A} \end{cases}$$

## Сходимость алгоритма

Оценим приращение функции за одну итерацию:

$$F(x_{k+1}) - F(x_k) = \frac{1}{2} \alpha_k^2 \langle r_k, r_k \rangle_A - \alpha_k \langle r_k, r_k \rangle = [\text{подставим } \alpha_k] = -\frac{1}{2} \frac{\langle r_k, r_k \rangle^2}{\langle r_k, r_k \rangle_A}$$

Предположим, что наш алгоритм не сходится, то есть  $\|r_k\|^2 = \langle r_k, r_k \rangle_A > \varepsilon > 0$ . Тогда изменение функции за один шаг можно оценить снизу константой, что означает, что за достаточное количество операций мы можем получить сколь угодно маленькое значение функции  $F(x)$ , что противоречит существованию минимума функции

## 4.2 Метод сопряженных градиентов


Метод наискорейшего спуска предельно прост и интуитивно понятен. К сожалению, в некоторых случаях скорость сходимости метода может быть не высока (например, когда у матрицы  $A$  большее число обусловленности), так как векторы  $r_k$  могут быть линейно зависимы. Эта проблема решается в следующем методе: мы будем запоминать направление на предыдущих шагах

### Описание метода

- Инициализация:  $x_1 = 0$  (обязательно),  $r_1 = b$ ,  $d_1 = r_1$  — вектор направлений
- $k$ -ая итерация:

$$\begin{cases} x_{k+1} = x_k + \alpha_k d_k \\ r_{k+1} = r_k - \alpha_k A d_k \\ \alpha_k = \frac{\langle d_k, r_k \rangle}{\langle d_k, d_k \rangle_A} \end{cases}$$

Коэффициент  $\alpha_k$  находится аналогично предыдущему методу, минимизируя  $F(x_k + \alpha d_k)$  по  $\alpha$ . Нетривиально вычисляется вектор  $d_{k+1}$ . В предыдущем методе мы всегда вдоль вектора невязки, теперь же мы смещаться вдоль ортогональной проекции вектора невязки  $r_{k+1}$  на вектор направлений  $d_k$



- В итоге алгоритм имеет следующий вид:

$$\begin{cases} x_{k+1} = x_k + \alpha_k d_k \\ r_{k+1} = r_k - \alpha_k A d_k \\ \alpha_k = \frac{\langle d_k, r_k \rangle}{\langle d_k, r_k \rangle_A} \\ d_{k+1} = r_{k+1} - \frac{\langle r_{k+1}, d_k \rangle_A}{\langle d_k, d_k \rangle_A} d_k \end{cases}$$

## Свойства

**Утверждение 26.** Все векторы  $r_k$  ортогональны между собой:

$$\forall k_1 \neq k_2 : \langle r_{k_1}, r_{k_2} \rangle = 0$$

$A$  также все  $d_k$   $A$ -ортогональны между собой:

$$\forall k_1 \neq k_2 : \langle d_{k_1}, d_{k_2} \rangle_A = 0$$

*Доказательство.* Будем доказывать по индукции по номеру итераций.

- База  $k = 2$ . Проверим, что  $\langle r_1, r_2 \rangle = 0$  и  $\langle d_1, d_2 \rangle_A = 0$ .

$$\langle r_1, r_2 \rangle = \left\langle r_1, r_1 - \frac{\langle d_1, r_1 \rangle}{\langle d_1, d_1 \rangle_A} Ad_1 \right\rangle = \langle r_1, r_1 \rangle - \frac{\langle d_1, r_1 \rangle}{\langle d_1, d_1 \rangle_A} \langle r_1, Ad_1 \rangle = \langle r_1, r_1 \rangle - \frac{\langle r_1, r_1 \rangle}{\langle r_1, r_1 \rangle_A} \langle r_1, r_1 \rangle_A = 0$$

$\langle d_1, d_2 \rangle_A = 0$  по определению.

- Предположение и шаг. Пусть вычислены  $r_1, \dots, r_k$  и  $d_1, \dots, d_k$  и выполнены условия ортогональности. Заметим, что

$$\text{span}(r_1, \dots, r_k) = \text{span}(d_1, \dots, d_k),$$

Можно доказать это равенство по индукции используя правила вычисления  $r_{k+1}$  и  $d_{k+1}$  в процессе алгоритма:

$$\begin{aligned} r_{k+1} &= r_k - \alpha_k Ad_k \\ d_{k+1} &= r_{k+1} - \frac{\langle r_{k+1}, d_k \rangle_A}{\langle d_k, d_k \rangle_A} d_k \end{aligned}$$

- Докажем ортогональность  $r_k$ . Вычислим  $r_{k+1}$  по определению:

$$r_{k+1} = r_k - \frac{\langle d_k, r_k \rangle}{\langle d_k, d_k \rangle_A} Ad_k$$

Поэтому вместо проверки  $\langle r_{k+1}, r_i \rangle$  для  $i \leq k$  можно проверить, что  $\langle r_{k+1}, d_i \rangle$  для  $i \leq k$ . Эти утверждения равносильны. Случай  $i = k$  проверяется построением. Для  $i < k$ :

$$\langle r_{k+1}, d_i \rangle = \langle r_k, d_i \rangle - \frac{\langle d_k, r_k \rangle}{\langle d_k, d_k \rangle_A} \langle d_i, Ad_i \rangle = 0 - 0 = 0 \text{ по предположению индукции}$$

- Докажем теперь  $A$ -ортогональность  $d_k$ . Случай  $i = k$  проверяется построением. Для  $i < k$ : По определению  $r_{i+1}$ :

$$r_{i+1} = r_i - \alpha_i Ad_i \iff Ad_i = \beta_i (r_{i+1} - r_i)$$

По определению  $d_{k+1}$ :

$$d_{k+1} = r_{k+1} - \text{pr}_{d_k} r_{k+1} = r_{k+1} - \frac{\langle r_{k+1}, d_k \rangle_A}{\langle d_k, d_k \rangle_A} d_k$$

Рассмотрим  $\langle d_i, d_{k+1} \rangle_A = \langle Ad_i, d_{k+1} \rangle$ :

$$\begin{aligned} \langle Ad_i, d_{k+1} \rangle &= \beta_i \langle r_{i+1} - r_i, r_{k+1} \rangle - \beta_i \frac{\langle r_{k+1}, d_k \rangle_A}{\langle d_k, d_k \rangle_A} \langle r_{i+1} - r_i, d_k \rangle = \\ &= \beta_i \langle r_{i+1} - r_i, r_{k+1} \rangle - \frac{\langle r_{k+1}, d_k \rangle_A}{\langle d_k, d_k \rangle_A} \langle Ad_i, d_k \rangle = 0 - 0 \text{ по предположению индукции} \end{aligned}$$

□

### Каноническая запись

Найдем теперь  $\langle d_k, r_k \rangle$ , выразив  $d_k$ :

$$\langle d_k, r_k \rangle = \langle r_k - \beta_k d_{k-1}, r_k \rangle = \langle r_k, r_k \rangle - \beta_k \langle r_k, d_{k-1} \rangle = \langle r_k, r_k \rangle - 0 = \langle r_k, r_k \rangle$$

Так как линейные оболочки  $\text{span}(r_1, \dots, r_k) = \text{span}(d_1, \dots, d_k)$  для всех  $k$ , то и  $\langle r_k, d_{k-1} \rangle = 0$ . Тогда получаем следующее:

$$r_{k+1} = r_k - \frac{\langle r_k, r_k \rangle}{\langle d_k, d_k \rangle_A} Ad_k$$

Рассмотрим  $\langle r_{k+1}, d_k \rangle_A = \langle r_{k+1}, Ad_k \rangle$ . Подставим  $Ad_k$  из выражения выше:

$$\langle r_{k+1}, Ad_k \rangle = \left\langle r_{k+1}, \frac{\langle d_k, d_k \rangle_A}{\langle r_k, r_k \rangle} \cdot (r_k - r_{k+1}) \right\rangle = -\langle r_{k+1}, r_{k+1} \rangle \cdot \frac{\langle d_k, d_k \rangle_A}{\langle r_k, r_k \rangle}$$

Получаем, что

$$d_{k+1} = r_{k+1} + \frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle} d_k$$

Итоговый алгоритм на  $k$ -ой итерации:

$$\begin{cases} x_{k+1} = x_k + \alpha_k d_k \\ r_{k+1} = r_k - \alpha_k Ad_k \\ \alpha_k = \frac{\langle r_k, r_k \rangle}{\langle d_k, d_k \rangle_A} \\ \beta_k = \frac{\langle r_{k+1}, r_{k+1} \rangle}{\langle r_k, r_k \rangle} \\ d_{k+1} = r_{k+1} + \beta_k d_k \end{cases}$$

## 5 Метод бисопряженных градиентов

### Напоминание

На прошлой лекции рассматривалась следующая задача:

$$Ax = b,$$

где  $A_{n \times n}$  — SPD матрица. Для таких матриц и был придуман метод сопряженных градиентов, который сходится за  $n$  шагов в точной арифметике

- Инициализация:  $x_1 = 0$  (обязательно),  $r_1 = b$ ,  $d_1 = r_1$  — вектор направлений
- $k$ -ая итерация:

$$\begin{cases} x_{k+1} = x_k + \alpha_k d_k \\ r_{k+1} = r_k - \alpha_k A d_k \\ \alpha_k = \frac{\langle d_k, r_k \rangle}{\langle d_k, d_k \rangle_A} \end{cases}$$

Одной из главных особенностей метода сопряженных градиентов является ортогональность векторов невязок  $r_k$  и направлений  $d_k$  — ключевое свойство для доказательства сходимости за  $n$  шагов. Можно ли построить такой же алгоритм для несимметричной матрицы  $A$ ?

### Двойственность

**Определение 27.** Пусть  $V$  — линейное пространство над полем  $\mathbb{F}$ . Тогда двойственным (или сопряженным) к нему пространством назовем:

$$V^* = \{f : V \longrightarrow \mathbb{F} : f \text{ — линейное над } \mathbb{F}\}$$

Скалярное произведение на линейном пространстве  $V$  позволяет отождествить само пространство  $V$  со множеством линейных функций на  $V$ :

$$f(x) = f\left(\sum_i x_i e_i\right) = \sum_i x_i f(e_i) = \sum_i x_i f_i = \langle x, f \rangle,$$

то есть в ортонормированном базисе линейной функции со значениями  $f_i$  на базисных векторах  $e_i$  ставится в соответствие вектор  $[f_1, \dots, f_n]^\top$

Но если на пространстве  $V$  не задано скалярное произведение, то и соответствия между  $V$  и пространством его линейных функций можно построить, но будет зависеть от выбора базиса

По этой причине в методе бисопряженных градиентов строятся 4 последовательности векторов: 2 последовательности векторов и 2 последовательности связанных с ними функций

### Двойственность и линейные операторы

Пусть  $A : V \longrightarrow V$  — линейный оператор,  $f : V \longrightarrow \mathbb{R}$  — линейная функция. Возьмем произвольный  $x \in V$ :

$$f^\top A x = f(Ax) = \sum_i f_i \sum_j A_{ij} x_j = \sum_j \left( \sum_i A_{ij} f_i \right) x_j = (A^* f)(x) = (A^\top f)^\top x$$

То есть по  $A$  мы можем построить линейный оператор  $A^* : V^* \longrightarrow V^* : A^* = A^\top$

## 5.1 Алгоритм

- Инициализация  $x_1$ . По начальному приближению строится вектор невязки  $r_1 = b - Ax_1$ .  
Затем задается линейная функция  $\hat{r}_1 = \hat{r}_1(r_1) = \hat{r}_1^\top r_1 \neq 0$ . Наиболее популярный вариант:  $\hat{r}_1 = r_1$   
Векторы направлений строятся как  $p_1 = r_1, \hat{p}_1 = \hat{r}_1$
- $k + 1$ -ая итерация:

$$\begin{cases} x_{k+1} = x_k + \alpha_k p_k \\ r_{k+1} = r_k - \alpha_k A p_k \\ \hat{r}_{k+1} = \hat{r}_k - \alpha_k A^\top \hat{p}_k \\ p_{k+1} = r_{k+1} + \beta_k p_k \\ \hat{p}_{k+1} = \hat{r}_{k+1} + \beta_k \hat{p}_k \\ \alpha_k = \frac{\hat{r}_k^\top r_k}{\hat{p}_k^\top A p_k} \\ \beta_k = \frac{\hat{r}_{k+1}^\top r_{k+1}}{\hat{r}_k^\top r_k} \end{cases}$$

## 5.2 Доказательство алгоритма

### Ортогональность

**Утверждение 28.** Для любых  $i \neq j$  выполняются следующие условия:

$$\begin{cases} \langle \hat{r}_i, r_j \rangle = \hat{r}_i^\top r_j = 0 \\ \langle \hat{p}_i, A p_j \rangle = \hat{p}_i^\top A p_j = 0 \end{cases}$$

*Доказательство.* Доказываем по индукции  $k = \max(i, j)$

- Заметим, что (доказывается по индукции)

$$\begin{aligned} \text{span}(r_1, \dots, r_k) &= \text{span}(p_1, \dots, p_k) \\ \text{span}(\hat{r}_1, \dots, \hat{r}_k) &= \text{span}(\hat{p}_1, \dots, \hat{p}_k) \end{aligned}$$

- Пусть  $j = k + 1, i < k$ :

$$\begin{aligned} \hat{r}_i^\top r_{k+1} &= \hat{r}_i^\top r_k - \alpha_k \hat{r}_i^\top A p_k = 0 - 0 = 0 \\ \hat{p}_i^\top A p_{k+1} &= \hat{p}_i^\top \cdot \frac{r_k - r_{k+1}}{\alpha_k} = \frac{1}{\alpha_k} \hat{p}_i^\top r_k - \frac{1}{\alpha_k} \hat{p}_i^\top r_{k+1} = 0 - 0 = 0 \end{aligned}$$

- Для  $i = k$  ортогональность выполняется из-за выбора коэффициентов  $\alpha_k$  и  $\beta_k$ :

$$\hat{r}_k^\top r_{k+1} = \hat{r}_k^\top r_k - \alpha_k \hat{r}_k^\top A p_k = \hat{r}_k^\top r_k - \alpha_k \hat{p}_k^\top A p_k + \beta_{k-1} \alpha_k \hat{p}_{k-1}^\top A p_k = 0 \text{ (подставим } \alpha_k \text{)}$$

Аналогично для векторов направлений:

$$\hat{p}_k^\top A p_{k+1} = (A^\top \hat{p}_k)^\top p_{k+1} = (A^\top \hat{p}_k)^\top r_{k+1} + \beta_k (A^\top \hat{p}_k)^\top p_k = -\frac{1}{\alpha_k} \hat{r}_{k+1}^\top r_{k+1} + \beta_k (A^\top \hat{p}_k)^\top p_k = 0$$

□

## 5.3 Проблемы алгоритма

## 6 Предобуславливание



## 7 Собственные векторы и собственные значения

**Определение 29.** Собственным вектором  $v$  матрицы  $A_{n \times n}$  с соответствующим собственным значением  $\lambda$  называется вектор, для которого выполнено:

$$Av = \lambda v$$

### Постановка задачи: SPD матрица

Задача нахождения (всех или нескольких) собственных векторов и собственных значений часто возникает на практике, особенно случай, когда  $A_n$  является SPD матрицей, который будет рассматриваться сейчас

Для SPD матрицы известно, что существует ортонормированный базис из собственных векторов  $e_1, \dots, e_n$  с собственными значениями  $\lambda_1, \dots, \lambda_n$ , где  $\lambda_i > 0$

### 7.1 Степенной метод

#### Описание метода

Следующий метод позволяет найти собственный вектор и соответствующее наибольшее собственное значение матрицы  $A$

- Сгенерируем случайный вектор  $v_0 : v_0^\top v_0 = 1$
- Посчитаем  $x_1 = Av_0$  и отнормируем его
- Проделаем то же самое с вектором  $v_0 = x_1$
- При достаточном количестве итераций получим  $v_0$  — собственный вектор с наибольшим собственным значением:

$$\lambda = \frac{v_1^\top v_0}{v_0^\top v_0}$$

#### Сходимость метода

Введем  $\|\cdot\|_2$  норму. Пусть у матрицы  $A$  есть базис из ортонормированных собственных векторов  $e_1, \dots, e_n$  и соответствующими собственными значениями  $\lambda_1 > \lambda_2 \geq \dots \geq \lambda_n$ . Пусть  $v_0 = \sum x_i e_i$  — некоторый вектор единичной длины с  $x_1 \neq 1$ . Определим последовательность

$$v_{k+1} = \frac{Av_k}{\|Av_k\|}$$

$$\|Av_k\| \cdot v_{k+1} = Av_k = A^k v_0 = \sum_{i=1}^n x_i A^k e_i = \sum_{i=1}^n x_i \lambda_i^k e_i = \lambda_1^k \left( x_1 e_1 + \sum_{i=2}^n x_i \cdot \left( \frac{\lambda_i}{\lambda_1} \right)^k e_i \right)$$

Вспомним, что  $\lambda_i/\lambda_1 < 1$ , поэтому при достаточно больших  $k$ :

$$\|Av_k\| \cdot v_{k+1} = Av_k = \lambda_1^k (x_1 e_1 + \varepsilon_k),$$

где  $\|\varepsilon_k\| \rightarrow 0$ . Рассмотрим при  $k \rightarrow \infty$

$$\|v_{k+1} - e_1\| = \left\| \frac{Av_k}{\|Av_k\|} - e_1 \right\| = \frac{1}{\|Av_k\|} \cdot \|\lambda_1^k (x_1 e_1 + \varepsilon_k) - \|Av_k\| \cdot e_1\| \leq \frac{1}{\|Av_k\|} \cdot \left| \lambda_1^k x_1 - \|Av_k\| \right| \cdot \|e_1\| \rightarrow 0$$

Теперь последовательность:

$$r_{k+1} = \frac{\langle v_{k+1}, v_k \rangle}{\langle v_k, v_k \rangle} = \frac{v_k^\top Av_k}{v_k^\top v_k} \rightarrow \lambda \cdot \frac{v_k^\top v_k}{v_k^\top v_k} = \lambda$$

### Как искать остальные?

Зафиксируем сколь угодно малое  $\varepsilon > 0$ . Пусть мы нашли собственный вектор  $v_1$  с наибольшим собственным значением  $\lambda_1$ . Построим матрицу  $B = A - (\lambda_1 - \varepsilon)v_1v_1^\top$ . Так как  $A$  является SPD матрицей, то

$$A = UDU^\top,$$

где  $U$  — ортогональная матрица, столбцы которой являются ортонормированными собственными векторами,  $D$  — диагональная матрица из собственных значений  $\lambda_i > \varepsilon$ . Поэтому  $A = \sum \lambda_i v_i v_i^\top$ . Тогда

$$B = A - (\lambda_1 - \varepsilon)v_1v_1^\top = \varepsilon v_1v_1^\top + \sum_{i=2}^n \lambda_i v_i v_i^\top$$

Тогда если применить степенной метод для матрицы  $B$ , то мы можем получить собственный вектор со следующим по величине собственным значением

**Замечание** Чтобы найти наименьшее собственное значение и соответствующий собственный вектор, то можем применить алгоритм к матрице  $A^{-1}$ . Чтобы вычислить  $A^{-1}v_k$ , мы можем вместо поиска  $A^{-1}$ , решать СЛУ  $Az_k = v_k \iff z_k = A^{-1}v_k$

### Поиск конкретного собственного значения

Пусть у матрицы  $A$  есть собственные значения  $\lambda_1, \dots, \lambda_n$  и мы хотим найти  $\lambda_i$ . Пусть мы знаем некоторое приближение  $\lambda_i^*$ . Определим тогда матрицу  $B = A - \lambda_i^* I$  и рассмотрим ее спектр

$$\text{spec}(B) = \{\lambda_k - \lambda_i^*\} \implies \text{spec}(B^{-1}) = \left\{ \frac{1}{\lambda_k - \lambda_i^*} \right\}$$

Получается, что если мы подобрали хорошее начальное приближение  $\lambda_i^*$ , то  $1/(\lambda_i - \lambda_i^*)$  — будем наибольшим собственным значением матрицы  $B^{-1}$ , которое мы можем найти с помощью степенного метода

## 7.2 QR-разложение

Следующий метод позволяет найти сразу несколько  $m$  наибольших собственных значений и собственных векторов

Введем  $\|\cdot\|_2$  норму. В этом методе нам понадобится процесс [ортогонализации Грамма-Шмидта](#). Пусть у нас есть векторы  $v_1, \dots, v_n$  и мы хотим получить ортонормированный базис  $e_1, \dots, e_n$ . Процесс описывается следующим образом:

- Пусть  $u_1 = v_1$ . Теперь будем вычислять векторы  $u_2, \dots, u_n$  следующим образом:

$$u_k = v_k - \sum_{j=1}^{k-1} \text{pr}_{u_j}(v_k),$$

где  $\text{pr}_{u_j}(v_k)$  — проекция вектора  $v_k$  на  $u_j$

- Теперь  $e_i = u_i / \|u_i\|$

### Описание метода

Пусть  $V_{n \times m} = V_0 = (v_1 | \dots | v_m)$  — матрица, чьи столбцы  $v_i$  являются ортонормированными векторами. Тогда будем итеративно вычислять матрицу:

$$V_{k+1} = \text{ORT}(AV_k),$$

где  $\text{ORT}$  — процесс ортогонализации Грамма-Шмидта

При достаточно большом  $k$  мы получим, что столбцы матрицы  $V_k$  являются собственными векторами  $e_1, \dots, e_m$  с собственными значениями  $\lambda_1 \geq \dots \geq \lambda_m$

### **Сходимость метода**

Сходимость этого метода доказывается аналогично прошлому методу

**Замечание** Аналогично прошлому методу мы можем найти первые  $m$  наименьших собственных значений, применив метод к матрице  $A^{-1}$